

Equipe 2: Classificação de Imagens de Culturas Agrícolas

Alunos: D'arc Mary
Denise Soares



Sumário

1. Introdução
2. Metodologia
3. Resultados
4. Conclusões
5. Referências Bibliográficas

Introdução

- 1.** Problema: Classificar imagens de culturas agrícolas corretamente
- 2.** Justificativa: A automação nesse setor pode melhorar o monitoramento de plantações e reduzir custos.
- 3.** Objetivo: Comparar modelos de deep learning (CNN e Transfer Learning com VGG16) para classificar 30 tipos de culturas agrícolas com base em imagens.



Metodologia

Base de dados

- Fonte: Kaggle – "Agricultural-crops-image-classification" dataset.
- Classes: 30 tipos de culturas.
- Quantidade de imagens: 829 imagens.
- Quantidade de duplicadas: 44 imagens

Metodologia

Método utilizado

Pré-processamento

- Redimensionamento de imagens (target_size (224, 224))
- Limpeza das duplicadas
- Técnicas de Data Augmentation: rotação, deslocamento, zoom, flip horizontal.

Modelos treinados

CNN simples do zero.

```
Total params: 114,397 (446.86 KB)
Trainable params: 113,949 (445.11 KB)
Non-trainable params: 448 (1.75 KB)
```

```
accuracy: 0.0881 - loss: 4.5862 - val_accuracy: 0.0177 - val_loss: 3.3972
accuracy: 0.1665 - loss: 3.4893 - val_accuracy: 0.0088 - val_loss: 3.5428
accuracy: 0.2711 - loss: 3.0209 - val_accuracy: 0.0088 - val_loss: 3.8815
accuracy: 0.3078 - loss: 2.7400 - val_accuracy: 0.0088 - val_loss: 4.7790
accuracy: 0.3408 - loss: 2.5726 - val_accuracy: 0.0088 - val_loss: 6.5997
```

- Quantidade de dados insuficiente
- Classes visualmente semelhantes
- Modelo ainda muito complexo para o cenário

Modelos treinados

Transfer Learning

Total params: 2,425,693 (9.25 MB)

Trainable params: 167,709 (655.11 KB)

Non-trainable params: 2,257,984 (8.61 MB)

Época	Acurácia (treino)	Acurácia (validação)	Perda (validação)
1	50.4%	68.1%	1.22
2	55.8%	66.3%	1.23
3	60.0%	64.6%	1.23
4	65.6%	64.6%	1.24
5	68.7%	63.7%	1.25

- Implementação do Transfer Learning com MobileNetV2

- Fine-Tuning da MobileNetV2

Resultados

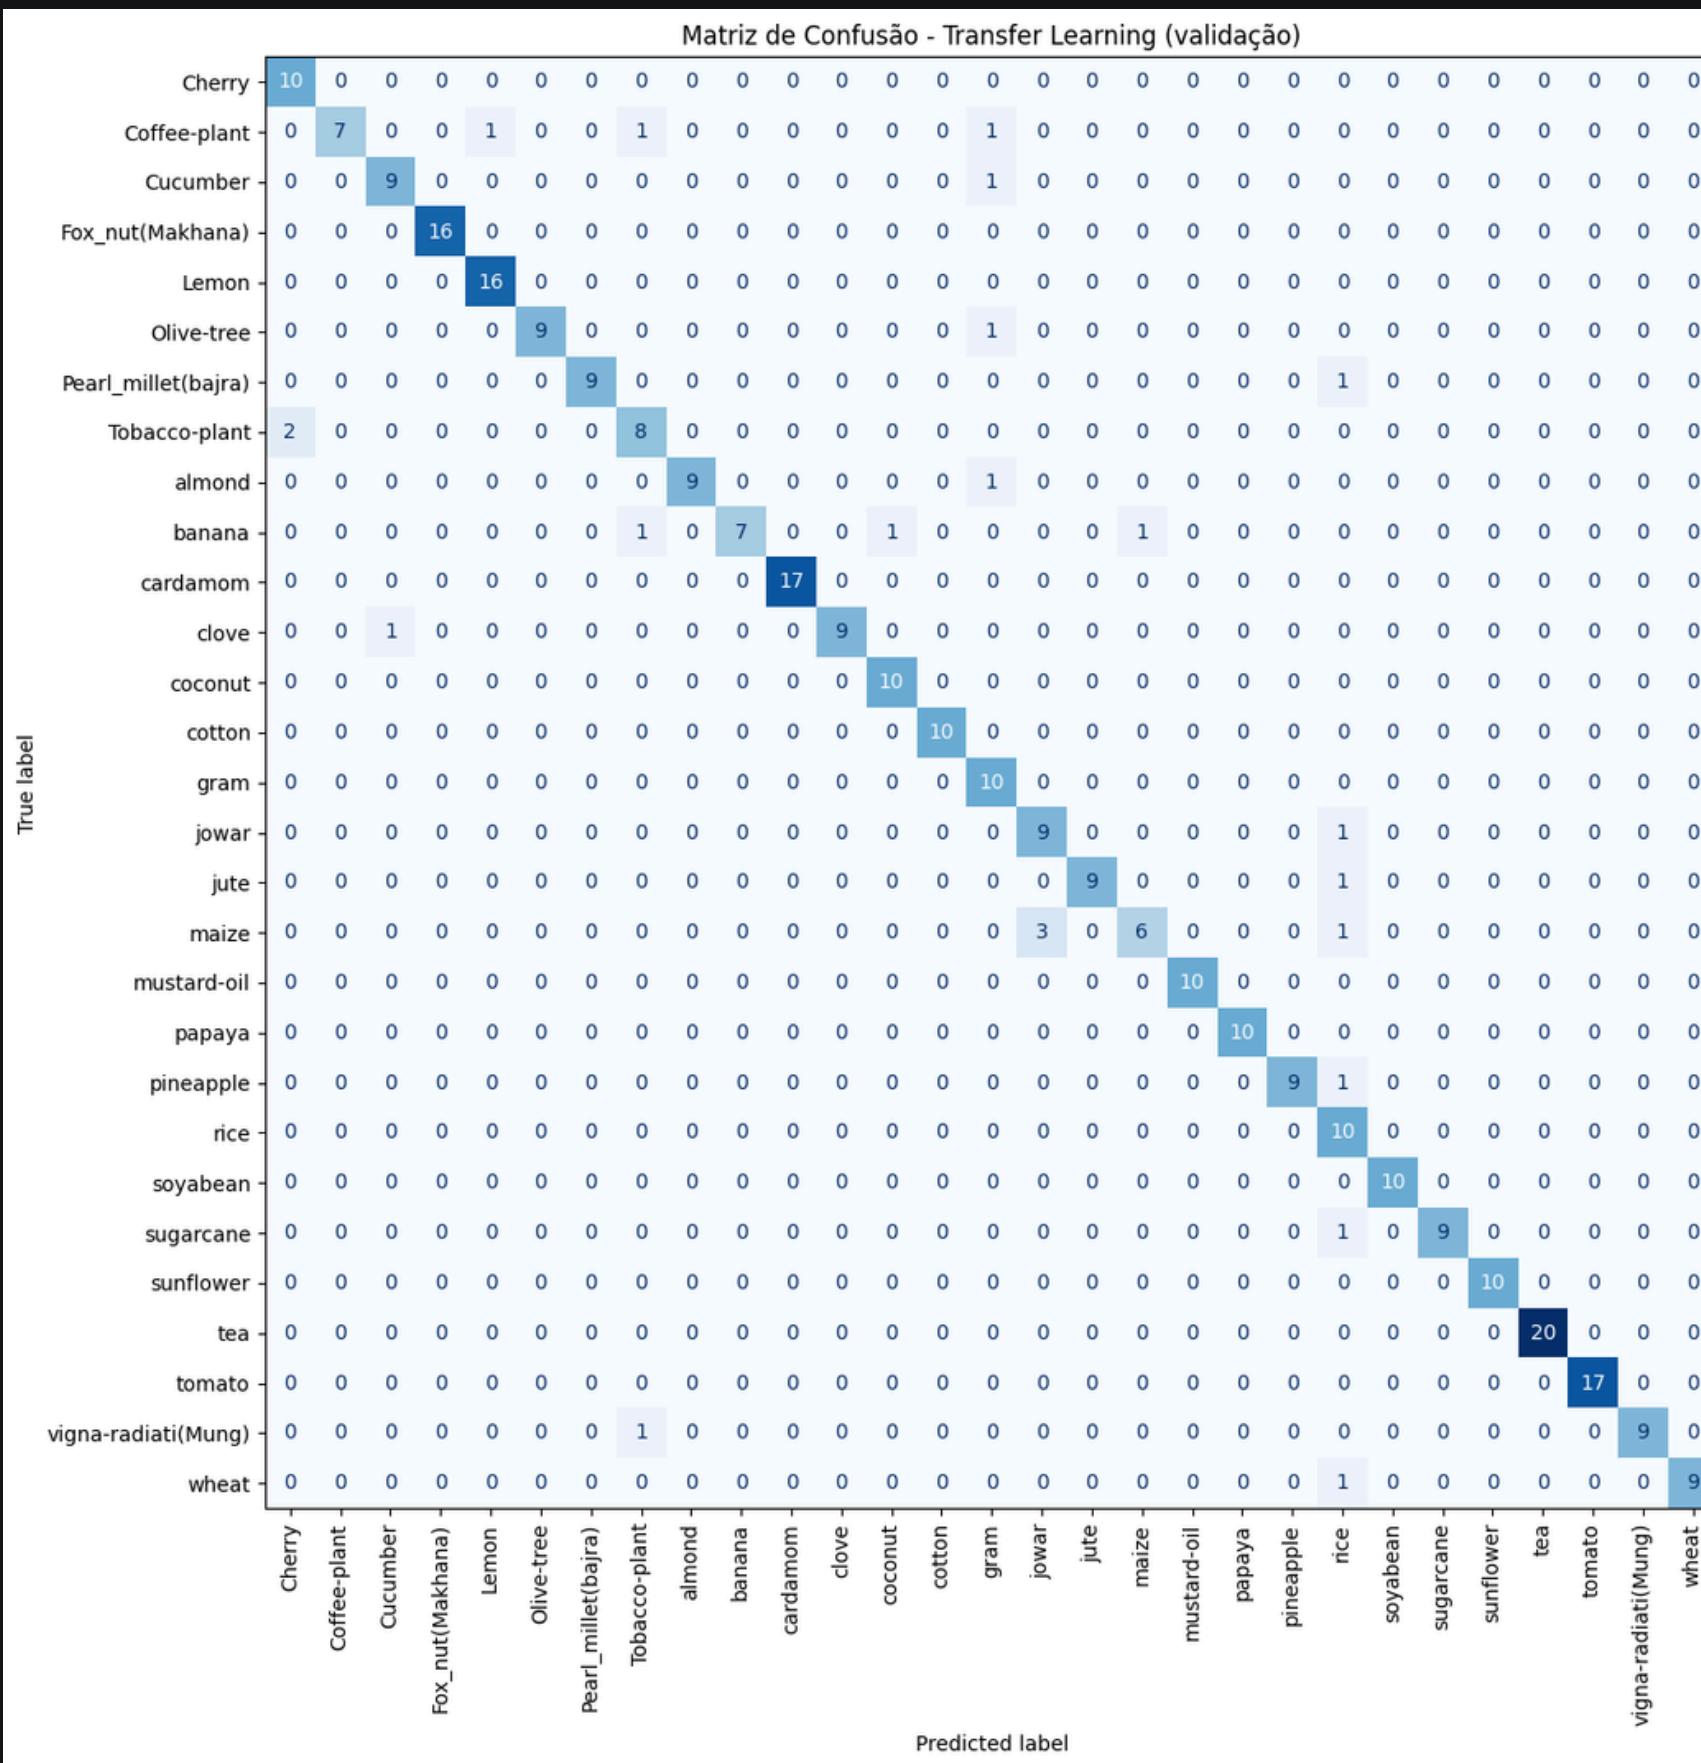
CNN X Transfer Learning

Critério	CNN (do zero)	Transfer Learning (congelado)	Transfer Learning (fine-tuning)
0 Épocas	5	10	+5
1 Melhor val_accuracy	~0.00	0.6637	0.6814
2 Melhor val_loss	>5.00	1.2300	1.2199
3 Overfitting observado?	🟡 Sim	🔴 Não	🟡 Leve tendência
4 Tempo de treino	Rápido	Médio	Médio-alto
5 Robustez com poucos dados	Baixa	**Alta**	Boa
6 Fine-tuning fez diferença?	—	—	Marginal (não compensou muito)

O fine-tuning aumentou a capacidade de adaptação do modelo ao problema, mas, por liberar pesos das camadas finais da MobileNetV2, exige maior cuidado com regularização (como Dropout e Data Augmentation), especialmente em datasets pequenos.

Resultados

Interpretação da Matriz



- Predominância na diagonal:** modelo teve bom desempenho geral.
- Classes com alta acurácia:**
 - Fox nut, Lemon, Tea, Tomato, Cardamom, Rice, Clove, Coconut
- Confusões pontuais:**
 - Almond, Coffee-plant, Banana, Olive-tree — confundidas com classes similares.
 - Erros dispersos residuais:
 - Ex: Coffee-plant previsto como Tomato ou Tea.
- Oportunidades de melhoria:**
 - Ajuste fino com mais dados reais e reforço em classes com menor suporte.

Conclusões

O que aprendemos:

- Modelos CNN do zero são frágeis em bases pequenas
- Transfer Learning com base congelada pode ser mais adequada em certos casos
- Fine-tuning trouxe ganhos, mas também apresentou riscos
- Matriz de confusão pode esclarecer onde o modelo apresentou maior dificuldade

Próximos passos

- Testar com outras arquiteturas como ResNet, EfficientNet.
- Aplicar segmentação para detecção localizada.
- Coletar base de dados mais robusta ou com imagens em campo real.

Referências Bibliográficas

- Kaggle Dataset: Agricultural Crops Image Classification
- Papers e tutoriais de CNN, VGG16
- Documentação do Keras, Scikit-learn

Obrigada!

